

TraMEL: Traffic-based Malware Exemplar Learning

Jungmin Park et al., résumé par Mathurin DE CRECY, Philipp HANUSSEK, Anton VAN CLEEMPOT

Sorbonne Université, M2 Informatique

Objectifs

TraMEL permet l'apprentissage continu de données séquentielles, qui proviennent notamment de l'analyse du trafic réseau afin de repérer les paquets malveillants. TraMEL:

- garde un tampon des données les plus pertinentes des séquences précédentes (affinage) pour éviter l'oubli catastrophique
- est une méthode pour adapter rapidement un classificateur à de nouvelles données tout en utilisant peu de mémoire

Affinage

L'affinage est une deuxième phase d'entraînement qui permet de limiter l'oubli en réinjectant des données anciennes dans le modèle. Les données pour cette phase sont sélectionnées à l'aide d'un K-Means, la quantité de mémoire disponible y est limitée, par conséquent on réutilise des samples des mêmes données pour chaque affinage. La loss est définie en fonction de plusieurs copies du modèle à différentes phases d'entraînement.

$$\mathcal{L}_{refine} = \mathcal{L}_{CE} + \alpha \cdot \mathcal{L}_{past} + \beta \cdot \mathcal{L}_{current}$$

$$\text{où } \mathcal{L}_{CE} = \frac{1}{|E|} \sum_{(x,y) \in E} CE(f^{(i)}(x), y),$$


$$\mathcal{L}_{past} = \frac{1}{|E_{<i}|} \sum_{x \in E_{<i}} \|f^{(i)}(x) - f^{(i-1)}(x)\|_2^2,$$

$$\mathcal{L}_{current} = \frac{1}{|E_i|} \sum_{x \in E_i} \|f^{(i)}(x) - f^{(i)'}(x)\|_2^2,$$

avec $f^{(i)}(x)$ le modèle à la tâche i après affinage, $f^{(i)'}(x)$ le modèle à la tâche i avant affinage, E_i les exemples sélectionnés pour i .

Expériences

Lors de la sélection des données pour l'affinage l'article prend uniquement les n données les plus proches des centroïdes déterminés par le K-Means, à la place nous avons choisi de prendre n données aléatoires parmi les N ($N > n$) plus proches. On constate une nette amélioration du forgetting score, autrement dit la précision des tâches les plus anciennes augmente au dépens de celle des plus récentes, ce qui uniformise les performances du modèle. On peut interpréter cela tel que la sélection d'exemples moins proches des centroïdes dans la phase d'affinage permet une meilleure généralisation.



Compromis Stabilité-Plasticité




Figure: visualisation de la précision et de l'oubli du modèle en fonction des paramètres α et β .

TabNet

Les auteurs ont choisi de tester TraMEL en utilisant des transformers, cependant nous avons tenu à tester leur méthode sur un autre type de réseau de neurones, TabNet. Par rapport aux Transformers, ceux-ci ont l'avantage de s'entraîner beaucoup plus vite et de nécessiter beaucoup moins de paramètres. Ce modèle propose une approche similaire aux arbres de décision en sélectionnant des caractéristiques qui permettent de distinguer les classes, et sont particulièrement adaptés aux données sous forme tabulaire.




Figure: Comparaison accuracy et temps d'entraînement entre différents models/implémentations

TraMEL vs XGBoost

Selon de nombreux auteurs, l'apprentissage ensembliste (*ensemble learning*) est plus adapté que les transformers pour les données en forme de tableaux. Nous présentons des résultats qui démontrent clairement la supériorité des forêts de décision par rapport à TraMEL tant en terme de temps de calcul que de taux de précision. L'algorithme utilisé (XGBoost) est une implémentation améliorée de l'amplification des gradients.

Conclusion

TraMEL propose une approche d'apprentissage continu en combinant sélection d'exemplaires et phase d'affinage afin de limiter l'oubli. Nos expérimentations montrent que certaines modifications permettent d'améliorer l'équilibre stabilité-plasticité du protocole. Par ailleurs, nos résultats suggèrent que des architectures alternatives telles que TabNet ou d'autres méthodes comme XGBoost seraient plus adaptées pour TraMEL étant donné la nature tabulaire des datasets.

